

Guided Project: Finding the Best Markets to Advertise In

Encontrando os melhores mercados para investir

Imagine que somos uma empresa que possui uma plataforma web de cursos de programação. Muitos dos cursos são relacionados à desenvolvimento web e mobile principalmente, ainda que tenha outros segmentos como jogos, ou data science, e etc. Queremos promover essa plataforma através de investimento em propaganda, porém precisamos antes descobrir os melhores 2 mercados para anunciar.

Com objetivo de simplificar e baratear esse processo, podemos usar uma pesquisa existente para encontrar esses resultados. Uma boa alternativa é a Pesquisa New Coder da Free Code Camp que também é uma plataforma de cursos e como eles publicam artigos acabam atraindo diferentes públicos somando mais de 400 mil seguidores.

Os dados da pesquisa de 2017 foram publicados no GitHub

```
base <- read_csv("https://raw.githubusercontent.com/freeCodeCamp/2017-new-coder-survey")
```

```
## Rows: 18175 Columns: 136
## -- Column specification -----
## Delimiter: ","
## chr   (27): BootcampName, CityPopulation, CodeEventOther, CommuteTime, Count...
## dbl   (105): Age, AttendedBootcamp, BootcampFinish, BootcampLoanYesNo, Bootca...
## dtm   (4): Part1EndTime, Part1StartTime, Part2EndTime, Part2StartTime
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

Para explorar mais informações sobre os dados acima, podemos consultar esse link.

A base de dados possui pouco mais de 18 mil linhas com 136 colunas. Vamos utilizar ao longo do projeto alguns desses dados para chegar no público de interesse,

JobRoleInterest

Esse campo armazena o cargo de interesse das pessoas que responderam a pesquisa. Podemos olhar em busca de respostas que contenham palavras chave como “web” ou “mobile”.

```
base %>% select(JobRoleInterest) %>% slice_sample(n = 20)
```

```
## # A tibble: 20 x 1
##   JobRoleInterest
##   <chr>
## 1 Back-End Web Developer, Mobile Developer, Data Engineer, Full-Stack Web De~
## 2 Back-End Web Developer, Data Scientist, Game Developer, DevOps / SysAdmi~
## 3 User Experience Designer, Product Manager, Full-Stack Web Developer, Fro~
## 4 <NA>
## 5 <NA>
## 6 <NA>
## 7 Front-End Web Developer, Back-End Web Developer, User Experience Designer,~
## 8 Mobile Developer, Data Engineer, Back-End Web Developer, Data Scientist, ~
## 9 <NA>
## 10 <NA>
## 11 <NA>
## 12 <NA>
## 13 <NA>
## 14 Full-Stack Web Developer
## 15 <NA>
## 16 Back-End Web Developer, Information Security, Full-Stack Web Developer
## 17 <NA>
## 18 Full-Stack Web Developer
## 19 Data Engineer, Mobile Developer, User Experience Designer, Information S~
## 20 <NA>
```

A pesquisa permitia múltipla escolha, nulo, e até o preenchimento livre caso respondesse outros. Sendo assim mesmo tratando a informação em busca de cargos distintos retorna mais de 200 resultados.

```
cargos_distintos <-
strsplit(base$JobRoleInterest, ",") %>% #separa por vírgula
  unlist() %>% #retira da lista
  trimws() %>% #remove espaços
  unique()     #traz resultados únicos

cargos_distintos %>% length()
```

```
## [1] 209
```

```
cargos_distintos %>% head(30)
```

```
## [1] NA "Full-Stack Web Developer"
## [3] "Front-End Web Developer" "Back-End Web Developer"
## [5] "DevOps / SysAdmin" "Mobile Developer"
## [7] "Information Security" "Quality Assurance Engineer"
## [9] "Game Developer" "User Experience Designer"
## [11] "Data Scientist" "Data Engineer"
## [13] "Product Manager" "Ethical Hacker"
## [15] "security expert" "Technical Writer"
## [17] "Researcher" "Systems Engineer"
## [19] "Desktop Applications Programmer" "Robotics"
## [21] "Non technical" "UI Design"
## [23] "Software engineer" "email coder"
## [25] "Data analyst" "I dont yet know"
## [27] "UX developer/designer" "support scientific resaerch"
## [29] "AI and neuroscience" "Full Stack Software Engineer"
```

Temos em torno de 6 mil pessoas interessadas em mobile ou web, apesar de representar 1 terço da base ainda parece ser o suficiente para extrair algumas respostas.

```
#criando uma flag para identificar o público
```

```
base <-
  base %>%
  mutate(IsMobileWeb = ifelse(grepl("mobile", tolower(JobRoleInterest), fixed = T) |
                                grepl("web", tolower(JobRoleInterest), fixed = T),
                                1, 0))
```

```
#conferindo volume
```

```
base %>% select(IsMobileWeb) %>% table()
```

```
## IsMobileWeb
##      0      1
## 12140  6035
```

```
#agrupando com outras flags para conferir se faz sentido o resultado
```

```
base %>%
```

```
#removendo resultados com o Cargo de interesse nulo, pois
```

```
#alguns casos a flag é 1 mas o campo está nulo e atrapalha a verificação
```

```
filter(!is.na(JobRoleInterest)) %>%
group_by(IsMobileWeb,
          JobInterestMobile,
          JobInterestFullStack,
          JobInterestBackEnd,
          JobInterestFrontEnd) %>%
summarise(n=n())
```

`summarise()` has grouped output by 'IsMobileWeb', 'JobInterestMobile',
'JobInterestFullStack', 'JobInterestBackEnd'. You can override using the
`.groups` argument.

```
## # A tibble: 17 x 6
## # Groups:   IsMobileWeb, JobInterestMobile, JobInterestFullStack,
## #   JobInterestBackEnd [9]
##   IsMobileWeb JobInterestMobile JobInterestFullStack JobInterestBackEnd
##         <dbl>         <dbl>         <dbl>         <dbl>
## 1           0           NA           NA           NA
## 2           1           1           1           1
## 3           1           1           1           1
## 4           1           1           1           NA
## 5           1           1           1           NA
## 6           1           1           NA           1
## 7           1           1           NA           1
## 8           1           1           NA           NA
## 9           1           1           NA           NA
## 10          1           NA           1           1
## 11          1           NA           1           1
## 12          1           NA           1           NA
## 13          1           NA           1           NA
## 14          1           NA           NA           1
## 15          1           NA           NA           1
## 16          1           NA           NA           NA
## 17          1           NA           NA           NA
## # i 2 more variables: JobInterestFrontEnd <dbl>, n <int>
```

Características do público

País onde mora

É interessante saber onde as pessoas moram para direcionar a publicidade as regiões que elas se encontram. Na base existem 2 campos que indicam região:

- CountryCitizen: onde a pessoa nasceu
- CountryLive: onde a pessoa mora

Muitos casos as pessoas continuam morando onde nasceram, mas existe a probabilidade de muitas pessoas estarem morando em outro local, e é a localidade atual que nos importa para a análise.

```
base %>%
  filter(IsMobileWeb == 1) %>%
  group_by(CountryLive) %>%
  summarise(n=n()) %>%
  mutate(`%` = round(n/sum(n)*100,2)) %>%
  arrange(desc(n)) %>%
  head(10)
```

```
## # A tibble: 10 x 3
##   CountryLive      n    `%`
##   <chr>          <int> <dbl>
## 1 United States of America 2678 44.4
## 2 India                443  7.34
## 3 United Kingdom        281  4.66
## 4 Canada                221  3.66
## 5 <NA>                 128  2.12
## 6 Poland                121  2
## 7 Brazil               115  1.91
## 8 Germany              107  1.77
## 9 Russia                94  1.56
## 10 Australia            88  1.46
```

Como as informações na base estão no nível de países, vamos lidar como se cada país seja um mercado, um público alvo diferente.

Sendo assim vamos selecionar os maiores mercados, maior quantidade de pessoas (EUA, India, UK, Canada), pois os indicadores de sucesso serão melhores. É mais fácil convencer 10% de 2 mil pessoas, do que 100% de países com menos de 30 pessoas.

Além disso esses países falam inglês e terão mais pessoas interessadas numa plataforma que tem cursos nesse idioma.

```
publico_alvo <-
base %>%
  filter(IsMobileWeb == 1,
         CountryLive %in% c("United States of America",
```

```
"India",  
"United Kingdom",  
"Canada"))
```

Quanto pode arcar com custos educacionais

Dentre o público de interesse, qual o valor que podem arcar com despesas educacionais? Temos o campo `MoneyForLearning` e `MonthsProgramming` e se dividirmos uma informação pela outra chegamos a um custo mensal que a pessoa pode arcar.

É importante antes de garantir apenas selecionar o público que temos informação suficiente para efetuar o cálculo. Cerca de 372 pessoas não informaram algum dos campos e vamos descartar.

```
publico_alvo %>%  
  filter(is.na(MoneyForLearning) |  
         is.na(MonthsProgramming) |  
         MonthsProgramming == 0) %>%  
  nrow()
```

```
## [1] 372
```

```
publico_alvo <- publico_alvo %>%  
  filter(!is.na(MoneyForLearning) &  
         !is.na(MonthsProgramming) &  
         MonthsProgramming != 0)
```

```
publico_alvo <- publico_alvo %>%  
  mutate(spentPerMonth = MoneyForLearning/MonthsProgramming)
```

```
publico_alvo %>% select(MoneyForLearning,MonthsProgramming,spentPerMonth) %>% head()
```


```
## # A tibble: 6 x 3  
##   MoneyForLearning MonthsProgramming spentPerMonth  
##           <dbl>           <dbl>           <dbl>  
## 1             80             6             13.3  
## 2          1000             5             200  
## 3              0            12              0  
## 4              0             1              0  
## 5            200            12             16.7  
## 6            500            14             35.7
```

```
publico_alvo %>%
  group_by(CountryLive) %>%
  summarise(n = n(),
            spentMonth_max = max(spentPerMonth),
            spentMonth_mean = mean(spentPerMonth),
            spentMonth_median = median(spentPerMonth))
```

```
## # A tibble: 4 x 5
##   CountryLive          n spentMonth_max spentMonth_mean spentMonth_median
##   <chr>          <int>          <dbl>          <dbl>          <dbl>
## 1 Canada          200            5000           121.           0.943
## 2 India           385           10000           148.            0
## 3 United Kingdom   240            1400            50.4          0.486
## 4 United States of Ameri~ 2426           80000           257.           5.13
```

Parece que temos outliers que distorcem muito a média, vamos nos aprofundar melhor através de boxplots.

```
publico_alvo %>%
  ggplot(aes(x=CountryLive, y=spentPerMonth))+
  geom_boxplot()+
  ggtitle("Gasto educacional mensal em dólares por país")+
  xlab("País que mora")+
  ylab("Dólares gasto por mês")+
  scale_y_continuous(breaks = seq(0, 80000, by = 5000))+
  theme_bw()
```



Vamos entender esse outliers para decidir como lidar com eles. Criando uma flag para determinar quem é outlier a partir do ponto de corte de gasto maior igual a 2.500\$

```
publico_alvo <-
publico_alvo %>%
  mutate(flg_outlier = if_else(spentPerMonth >=2500,1,0))
```

Analisando alguns campos mais significantes para tentar mapear o perfil dessas pessoas, podemos notar que num geral que os outliers:

- representam apenas 53 pessoas
- que fizeram bootcamp, ou
- estão há poucos meses estudando, o que provavelmente indica que fez um alto investimento num curso
- e portanto tiveram um gasto maior em pouco tempo e distorcem nosso público de interesse.

Pois uma plataforma de cursos requer um custo menor e constante.

```
publico_alvo %>%
  group_by(flg_outlier) %>%
```


```
summarise(n = n(),
          spentPerMonth = mean(spentPerMonth),
          MonthsProgramming = mean(MonthsProgramming),
          AttendedBootcamp = mean(AttendedBootcamp, na.rm = T))
```

```
## # A tibble: 2 x 5
##   flg_outlier      n spentPerMonth MonthsProgramming AttendedBootcamp
##   <dbl> <int>      <dbl>          <dbl>          <dbl>
## 1         0  3198        98.0          14.4          0.0690
## 2         1   53       7588.          4.87          0.528
```

Sendo assim faz sentido remover esse público para analisar casos que se enquadram melhor em nossa análise.

```
publico_alvo_s_outlier <-
  publico_alvo %>%
  filter(flg_outlier == 0)
```

```
publico_alvo_s_outlier %>%
  ggplot(aes(x=CountryLive, y=spentPerMonth))+
  geom_boxplot()+
  ggtitle("Gasto educacional mensal em dólares por país")+
  xlab("País que mora")+
  ylab("Dólares gasto por mês")+
  theme_bw()
```



Se repetirmos os cálculos anteriores

```
publico_alvo_s_outlier %>%
  group_by(CountryLive) %>%
  summarise(n = n(),
            spentMonth_max = max(spentPerMonth),
            spentMonth_mean = mean(spentPerMonth),
            spentMonth_median = median(spentPerMonth))
```

```
## # A tibble: 4 x 5
##   CountryLive          n spentMonth_max spentMonth_mean spentMonth_median
##   <chr>          <int>         <dbl>         <dbl>         <dbl>
## 1 Canada        199          2337.           96.6           0.833
## 2 India         379          2000            64.6           0
## 3 United Kingdom 240          1400            50.4           0.486
## 4 United States of Ameri~ 2380          2429.          108.           5
```

Após remover os casos que distorciam nossa análise vemos como isso influencia no cálculo da média do gasto em dólares mensalmente com educação.

EUA que é com certeza uma boa escolha de público alvo para ofertar anúncios visto que há uma concentração maior de pessoas e tem costume de investir mais em educação.

Agora no caso de escolher entre UK, Índia e Canadá, podemos escolher a Índia pelo maior volume de pessoas, ou Canadá por investir um pouco mais em educação. UK fica de fora visto que o valor de assinatura da empresa é de 59\$ e portanto não seria interessante para esse público.