

Estimating Probabilities

Probabilidade - Termos utilizados

É comum no dia a dia lidarmos com as chances de algo acontecer. A previsão do tempo estima que o dia vai ser ensolarado e nos frustramos se acaba sendo nublado, ou num casino por exemplo aqueles que apostam lidam o tempo todo com as chances de o jogo se comportar a seu favor tentando maximizar seus lucros.

Matemáticos do passado criaram um framework no estudo para lidar com incertezas chamado **probabilidade**. Vamos aprender mais sobre esse tema e como incorporar na Ciência de Dados, mas primeiro precisamos aprender alguns termos através de alguns exemplos.

Começando com jogar uma moeda, chamamos isso de **Experimento Aleatório** (*Random Experiment*), não é exatamente um experimento científico, mas podemos entendê-lo como uma ação básica. Chamamos de aleatório, pois as chances de um dos lados da moeda ficar pra cima não é possível estimar até que tenha acontecido.

Um **possível resultado** (em inglês *outcome*) ao jogar uma moeda pode ser apenas cara ou coroa, mas ambos resultados representam todos os possíveis resultados do experimento aleatório (*all the outcomes of a random experiment*), o que nós chamamos também de **Espaço Amostral** (*sample space*).

Calculando a Probabilidade Teórica

Como calcularmos a probabilidade de o resultado da moeda ser 'coroa'? Intuitivamente sabemos que é a mesma de ser 'cara' e que existem apenas duas saídas possíveis. Assumindo que a moeda é honesta e as chances de ter cara ou coroa são de fato as mesmas, nós podemos dividir o resultado desejado pela quantidade de possíveis resultados:

$$P(\text{coroa}) = \frac{1}{2} = 50\%$$

É dessa forma que interpretamos a probabilidade, é uma medida numérica da probabilidade de um resultado acontecer

Outro exemplo é escolher uma carta num deck de 52 cartas

$$P(\text{uma carta}) = \frac{1}{52} = 1.92\%$$

Até aqui calculamos a probabilidade teórica, pois estamos assumindo que as chances dos resultados acontecerem são iguais. Na prática, assumir algo não é realista, as pessoas ao escolher vegetais num hortifruti avaliam antes de selecionar e, portanto, as chances de selecionar não são iguais para todos vegetais.

$$P(\text{resultado}) = \frac{1}{\text{todos resultados possiveis}} = \text{probabilidade}\%$$

Evento

Falamos sobre um resultado único ocorrer dentro de uma gama de possibilidades (Espaço Amostral), mas se queremos calcular a probabilidade para mais de um resultado?

Nesse caso usamos o termo **Evento**, o resultado olha uma possibilidade isolada, o evento pode ser composto de um ou mais resultados.

Imagine que queremos calcular a probabilidade de um dado de 6 lados cair em 1, 3 ou 5, cada um desses números representam resultados, mas o nosso evento de interesse é composto pelos 3 resultados.

$$P(\text{evento}) = \frac{\text{num de resultados que atendam o evento}}{\text{num de resultados possiveis no espaco amostral}} = \text{probabilidade}\%$$

Então o cálculo do dado acima seria:

$$P(\text{evento}) = \frac{1, 3, 5}{6} = \frac{3}{6} = 50\%$$

Calculando a Probabilidade Empírica

Até aqui calculamos em teoria as chances de um evento ocorrer dado um espaço amostral, mas temos como calcular e provar que isso está certo? Existe uma forma de estimar a probabilidade teórica dado um evento?

Podemos usar o Experimento Aleatório, nós podemos repetir o experimento numa certa quantidade de vezes e contar quantas vezes de fato o evento de interesse aconteceu.

$$est.P(evento) = \frac{\text{num de vezes que o evento aconteceu}}{\text{num de vezes que o experimento foi repetido}}$$

Voltando no exemplo da moeda, de acordo com a probabilidade teórica temos 50% de chances de cair cara ou coroa. Podemos jogar uma moeda várias vezes e anotar os resultados e contar quantas vezes caiu coroa (evento de interesse) contra a quantidade de vezes que a moeda foi jogada.

Imagine que a moeda foi jogada 100 vezes e 56 vezes deu coroa.

$$est.P(evento) = \frac{56}{100} = 56\%$$

O resultado da **Probabilidade Empírica** foi de 56%, foi um resultado observado de experimentos realizados.

O número 56 foi arbitrário, poderia ter caído coroa 47 vezes, outras vezes poderia ter sido mais ou menos. A cada experimento resulta numa probabilidade empírica diferente.

E como conciliamos esse resultado da Probabilidade Empírica com a Teórica?

Lei dos grandes números

Apesar de termos inventado esses exemplos com objetivo de ilustrar, podemos realizar esse experimento através da programação.

Abaixo criamos uma função que simula a jogada de uma moeda e consideramos sua probabilidade teórica de 50% para determinar se é cara ou coroa.

```

set.seed(1) #aqui garantimos a reprodutibilidade do exemplo

jogar_moeda <- function(){
  jogada <- runif(1) #geramos um único resultado que por padrão é entre 0 e 1

  if(jogada <= 0.5){
    return("CARA")
  }else{
    return("COROA")
  }
}

```

Agora vamos colocar num loop para definir a probabilidade empírica.

Começando com 10 jogadas.

```

coroa <- 0

for(i in seq(1,10,1)){
  coroa <- if_else(jogar_moeda() == "COROA", coroa+1, coroa)
}

prob_emp <- round(coroa/10 * 100,2)

print(glue("Quantidade de coroas: {coroa}"))

```

```
## Quantidade de coroas: 6
```

```
print(glue("Probabilidade Teórica: 50%"))
```

```
## Probabilidade Teórica: 50%
```

```
print(glue("Probabilidade Empírica: {prob_emp}%"))
```

```
## Probabilidade Empírica: 60%
```

E com 100 jogadas:

```
coroa <- 0

for(i in seq(1,100,1)){
  coroa <- if_else(jogar_moeda() == "COROA", coroa+1, coroa)
}

prob_emp <- round(coroa/100 * 100,2)

print(glue("Quantidade de coroas: {coroa}"))
```

```
## Quantidade de coroas: 47
```

```
print(glue("Probabilidade Teórica: 50%"))
```

```
## Probabilidade Teórica: 50%
```

```
print(glue("Probabilidade Empírica: {prob_emp}%"))
```

```
## Probabilidade Empírica: 47%
```

Rodando ambos códigos acima múltiplas vezes é possível notar que o loop com 10 jogadas se distancia mais da probabilidade teórica, as vezes atingindo 30% ou 90%. Já o loop de 100 jogadas se aproxima muito mais da probabilidade teórica, chegando a 42%, 53% etc.

Com isso notamos como a quantidade de experimentos influenciam a probabilidade empírica a se aproximar da teórica.

E muitas vezes não teremos o cálculo exato da probabilidade teórica para poder validar se a probabilidade empírica está correta, mas podemos nos atentar ao volume de experimentos para tentar garantir essa aproximação.