

Conditional Probability: Fundamentals

Probabilidade Condicional

Imagine que precisamos nos vestir para ir pra escola ou mesmo trabalhar, mas o dia está nublado, será que vai chover? Determinadas condições podem alterar a probabilidade de um evento ocorrer.

Para isso vamos entender algumas regras da probabilidade condicional.

Quando jogamos um dado de seis lados, sabemos que temos 6 possibilidades $\Omega = 1, 2, 3, 4, 5, 6$. As chances de o dado cair em 2 por exemplo é $P(2) = \frac{1}{6}$, pois apenas 1 resultado satisfaz o evento. Se o evento fosse cair um número par (2, 4 ou 6) dentre as 6 possibilidades a probabilidade seria $P(2, 4, 6) = \frac{3}{6}$.

Voltando um pouco, imagine que jogamos um dado de seis lados esperando que caísse em 2 $P(2) = \frac{1}{6}$. Mas no meio da jogada descobrimos que o dado caiu num número par. Agora sabemos que as possibilidades foram reduzidas de 6 $\Omega = 1, 2, 3, 4, 5, 6$ para 3 $\Omega = 2, 4, 6$

$$\Omega = 1, 2, 3, 4, 5, 6 \rightarrow \Omega|result\ eh\ par = 2, 4, 6$$

O símbolo *pipe* | pode ser lido como “dado”, ou seja, agora Omega é composto por 2, 4, 6 dado que sabemos que o resultado é par. Então agora o cálculo da probabilidade é feito considerando o novo tamanho do espaço amostral $P(2) = \frac{1}{3}$

Agora temos duas probabilidades diferentes, qual está certa? Ambas, pois cada uma responde uma pergunta diferente:

- Qual a probabilidade de conseguir 2?
- Qual a probabilidade de conseguir 2, dado que o dado caiu num número par?

Na segunda pergunta introduzimos uma **condição**, e a notação na fórmula para representar essa condição ficaria assim:

$$P(2|result\ eh\ par) = \frac{1}{3}$$

Repare que o número total de possibilidades no espaço amostral era inicialmente 6, e dado uma condição reduziu para 3, o nome dado para esse número é **cardinalidade**.


$$\text{card}(\Omega) = 6$$

Fórmula

Se o nosso evento A for ser um número par (2,4, ou 6), e sabemos que o dado caiu num número maior que 2 (evento B), ou seja (3,4,5,6), sabemos que o resultado precisa satisfazer A e B e só pode ser 4 ou 6. Logo temos uma intersecção de A com B $A \cap B$

```
x <- list(A = c(2,4,6),
          B = c(3,4,5,6))

ggvenn(
  x,
  fill_color = c("blue", "yellow"),
  stroke_size = 0.5,
  show_elements = T
)
```



Nesse caso podemos representar a fórmula assim:

$$P(A|B) = \frac{\text{card}(A \cap B)}{\text{card}(B)}$$

Exemplo

Trazendo para um caso mais realista, vamos imaginar um cenário onde um centro de pesquisa quer entender se um teste para HIV é confiável o bastante para ser aplicado num hospital

Tabela	P	P^C	Total
T	21	24	45
T^C	2	6	8
Total	23	30	53

Temos um total de 53 pessoas divididas em P = Pessoas com HIV e P^C = Pessoas sem HIV (complemento ao P). Além disso essas pessoas passaram pelo teste e

as que deram positivo são representadas por T , e quando o teste deu negativo foi representado por T^C (complemento ao T).

Isso significa que 23 pessoas tinham HIV porém apenas 21 delas foram detectadas pelo teste, ou seja 2 delas foram um **falso negativo** dizendo que não tem a doença no resultado do exame embora elas tenham. Enquanto que das 30 pessoas sem HIV, 24 delas deram **falso positivo**.

Agora o time de pesquisadores querem saber:

- 1- Qual a probabilidade de alguém testar positivo, dado que o paciente possui HIV? $P(T|P) = \frac{\text{card}(T \cap P)}{\text{card}(P)}$
- 2- Qual a probabilidade de alguém testar negativo, dado que o paciente não possui HIV? $P(T^C|P^C) = \frac{\text{card}(T^C \cap P^C)}{\text{card}(P^C)}$

Pergunta 1

- Sabemos que a intersecção entre quem testou positivo (T) com quem de fato tem a doença (P) é 21 ($\text{card}(T \cap P)$)
- Sabemos que 23 pessoas têm a doença ($\text{card}(P)$)

O resultado fica:

$$P(T|P) = \frac{\text{card}(T \cap P)}{\text{card}(P)} = \frac{21}{23} = 91,3\%$$

Pergunta 2

- Sabemos que a intersecção entre quem testou negativo (T^C) com quem não tem a doença (P^C) é 6 ($\text{card}(T^C \cap P^C)$)
- Sabemos que 30 pessoas não têm a doença ($\text{card}(P^C)$)

O resultado fica:

$$P(T^C|P^C) = \frac{\text{card}(T^C \cap P^C)}{\text{card}(P^C)} = \frac{6}{30} = 20\%$$

O resultado diz que de quem não tem a doença, apenas 20% foi dado como negativo, isso significa que tivemos muitos falsos positivos, e 80% dessa população sem HIV que foi incorretamente diagnosticado indica que o teste ainda precisa ser trabalhado antes de ser implementado para melhorar esse resultado.

Calcular sem a cardinalidade da condição

Às vezes não temos a cardinalidade do evento ou é um evento tão raro que fica difícil de colocar o valor exato na fórmula. $P(T|P) = \frac{\text{card}(T \cap P)}{\text{card}(P)}$

Então seria útil uma fórmula que não fosse baseada nas cardinalidades do evento.

Se ao invés de usarmos a cardinalidade no numerador e denominador, usássemos as probabilidades?

$$P(T|P) = \frac{P(T \cap P)}{P(P)} = \frac{\frac{21}{53}}{\frac{23}{53}} = 91,3\%$$

O resultado é o mesmo, funciona!

Voltando para o exemplo do teste de HIV, para o pesquisador buscar a probabilidade de o teste dar positivo para quem tem a doença $P(T|P)$ faz sentido, mas para o ponto de vista do paciente o que ele espera saber é dado que o teste T é positivo, quais as chances reais de ele realmente ter a doença $P(P|T)$. Apesar de parecer a mesma coisa, os resultados podem ser completamente diferentes.

Segundo os pesquisadores dessa outra pesquisa, $P(T) = 0.12$ e $P(P \cap T) = 0.000015$, então:

$$P(P|T) = \frac{P(P \cap T)}{P(T)} = \frac{0.000015}{0.12} = 0.000125 = 0.0125\%$$

Esse resultado por exemplo traria um pouco de alívio para o resultado, pois as chances de a pessoa ter a infecção são poucas.