

Bayes Theorem

Revisão de Independência vs Exclusividade

Para se aprofundar no tópico principal, vale antes recapitular esses conceitos.

Eventos serem exclusivos, significa que eles nunca acontecerão ao mesmo tempo (Ao jogar um dado a saída não pode ser par e ímpar ao mesmo tempo).

Já eventos serem independentes, significa que a ocorrência de um evento não diminui ou impacta nas chances do outro ocorrer (jogar uma vez o dado, não muda a saída ao jogar uma segunda vez. Diferente de uma carta que quando escolhemos uma carta num jogo com 52 cartas, ao escolher a segunda carta o jogo tem 51 cartas).

A fórmula de eventos independentes:

$$P(A \cap B) = P(A) * P(B)$$

Já quando eles são dependentes:

$$P(A \cap B) = P(A) * P(B|A)$$

Eventos exclusivos:

$$P(A \cap B) = 0$$

Revisão da Regra da adição

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Sabemos que para eventos mutuamente exclusivos será $P(A \cap B) = 0$ sendo assim podemos remover esse trecho da fórmula nesses casos:

$$P(A \cup B) = P(A) + P(B)$$

Vamos considerar um exemplo de teste de HIV:

- A probabilidade de o resultado do teste ser **positivo** e a pessoa **não estar** infectada é de $P(T|D^C) = 0.0105$.
- A probabilidade de o resultado do teste ser **positivo** e a pessoa **estar** infectada é de $P(T|D) = 0.9978$.
- A probabilidade de a pessoa **estar** infectada é de $P(D) = 0.0014$ (a prevalência da HIV)
- A probabilidade de a pessoa **não estar** infectada é de $P(D^C) = 0.9986$

Quando a gente abordou esse exemplo a primeira vez olhamos sob o contexto de probabilidade condicional $P(T|D)$. Mas e se a gente quiser olhar $P(T)$ isoladamente? Esse cenário pode ter 2 situações, a pessoa com teste positivo **está** ou **não está** infectada por HIV.

Quando pensamos num resultado de um teste, achamos que o resultado positivo automaticamente constata que a doença está presente, mas existe as chances de a pessoa ter, ou não ter e o teste ter errado. A probabilidade condicional nos lembra dessa possibilidade.

Esses 2 cenários podem ser descritos da seguinte forma:

$$P(T) = P(T \cap D) \cup (T \cap D^C)$$

Juntando ambas probabilidades (dado teste positivo T , **ter** D ou **não ter** HIV D^C) temos 100% de probabilidade do teste positivo. Podemos enxergar isso através da ilustração abaixo:



Figura 1: diagrama 1

A junção de pessoas com ou sem infecção de HIV representam 100% de probabilidade. Por isso chamamos esses eventos de **exaustivos** visto que cobrem todas as possibilidades dentro do espaço amostral Ω , uma vez que não existe meio termo na doença.

Eles são independentes, mutuamente exclusivos e exaustivos. Também podemos dizer que cada um é uma **partição** do espaço amostral.

Agora vamos adicionar o elemento T nesse diagrama para entender melhor a fórmula.




Figura 2: diagrama 2

Podemos notar que o teste positivo acontece em parte com aqueles que tem e parte em quem não tem HIV. A sobreposição de T em D demonstra a probabilidade interseccional. E uma vez que D e D^C são mutuamente exclusivos, o mesmo ocorre com as intersecções $T \cap D$ e $T \cap D^C$.

Isso tudo foi para ilustrar que a união de ambos pode ser feito através da soma de ambos.

$$P(T) = P(T \cap D) \cup (T \cap D^C)$$

Se torna:

$$P(T) = P(T \cap D) + (T \cap D^C)$$

Agora podemos representar $P(T)$ usando a regra da multiplicação

$$P(T) = P(D) * P(T|D) + P(D^C) * P(T|D^C)$$

$$P(T) = 0.0014 * 0.9978 + 0.9986 * 0.0105 = 0.0119$$

O resultado de 1.19% parece pouco mas é porque HIV já é um evento muito raro.

Exemplo

Agora que temos uma fórmula geral, vamos aplicar a mais um cenário:

$$P(A) = P(B) * P(A|B) + P(B^C) * P(A|B^C)$$

Imagine uma aviação onde temos:

- 73% viagens são feitas em Boeing
- Quando há delay, dado que o avião foi Boeing, representa 3% das viagens
- 27% viagens são feitas em Airbus
- Quando há delay, dado que o avião foi Airbus, representa 8% das viagens

$$P(Delay) = P(Boeing) * P(Delay|Boeing) + P(Airbus) * P(Delay|Airbus)$$

Ou seja, não sabemos o delay como um todo independente se for Boeing ou Airbus, mas com as informações fornecidas podemos calcular.

$$P(Boeing) = 0.73$$

$$P(Airbus) = 1 - P(Boeing) = 0.27$$

$$P(Delay|Boeing) = 0.03$$

$$P(Delay|Airbus) = 0.08$$

Substituindo essas partes na fórmula completa temos:

$$P(Delay) = 0.73 * 0.03 + 0.27 * 0.08 = 0.0435$$

Três Eventos

Vamos usar a mesma fórmula agora considerando 3 aviões. Boeing, Airbus e ERJ.

- 58% viagens são feitas em Boeing
- Quando há delay, dado que o avião foi Boeing, representa 4% das viagens
- 31% viagens são feitas em Airbus
- Quando há delay, dado que o avião foi Airbus, representa 7% das viagens
- 11% viagens são feitas em ERJ
- Quando há delay, dado que o avião foi ERJ, representa 2% das viagens

$$P(D) = P(B) * P(D|B) + P(A) * P(D|A) + P(E) * P(D|E)$$

$$P(Delay) = 0.58 * 0.04 + 0.31 * 0.07 + 0.11 * 0.02 = 0.0471$$

No caso a fórmula genérica para esse exemplo, visto que não é mais o evento E e um complemento E^C , é:

$$P(A) = P(B_1) * P(A|B_1) + P(B_2) * P(A|B_2) + P(B_3) * P(A|B_3)$$

A lei da probabilidade total

Note que para cada um dos exemplos estamos considerando os aviões do exemplo como o total de possibilidades no espaço amostral. Mas e se tiver n possibilidades?

$$\Omega = B_1, B_2, \dots, B_n$$

Da mesma forma, a fórmula amplia:

$$P(A) = P(B_1) * P(A|B_1) + P(B_2) * P(A|B_2) + \dots + P(B_n) * P(A|B_n)$$

E o nome dessa fórmula é **A lei da probabilidade total**. Quando temos muitas somas podemos representa-las pela letra grega da soma sigma Σ .

A fórmula continua sendo a mesma, mas reduzida na sua expressão para facilitar e o sigma representa o loop de n repetições.

$$P(A) = \sum_{i=1}^N P(B_i) * P(A|B_i)$$

Teorema de Bayes

Nós já aprendemos que se trocarmos de ordem o evento vs a condição a probabilidade é diferente ($P(A|B)$ ou $P(B|A)$). A Lei da probabilidade total nos permitiu entender melhor a relação dessas situações. Sabemos que a intersecção das probabilidade interseccional pode ser escrita de duas maneiras:

$$P(A \cap B) = P(A|B) * P(B)$$

$$P(A \cap B) = P(B|A) * P(A)$$

E isso acontece visto que a intersecção não muda independente do ponto de vista. E visto que ambas são iguais podemos derivar a fórmula:

$$P(A \cap B) = P(A|B) * P(B) = P(B|A) * P(A)$$

$$P(A|B) * P(B) = P(B|A) * P(A)$$

$$P(B|A) = \frac{P(A|B) * P(B)}{P(A)}$$

Essa fórmula sugere que existe uma razão entre A e B ($\frac{P(B)}{P(A)}$), vamos nos aprofundar nisso com mais um exemplo.

Voltando no exemplo dos 2 aviões Boeing e Airbus, a fórmula da Lei da Probabilidade Total nos ajudou a encontrar o delay geral dado que tínhamos as demais informações. Imagine que agora queremos na verdade descobrir o delay de um determinado avião. Em outras palavras, qual a probabilidade de o avião ser um Boeing dado que teve delay $P(Boeing|Delay)$? Veja que é diferente da informação que já temos, dado que é um Boeing teve delay em 3% $P(Delay|Boeing)$.

$$P(Delay) = P(Boeing)*P(Delay|Boeing)+P(Airbus)*P(Delay|Airbus)$$

$$P(Delay) = 0.73 * 0.03 + 0.27 * 0.08 = 0.0435$$

Agora podemos “plugar” na fórmula que construímos logo acima $P(B|A) = \frac{P(A|B)*P(B)}{P(A)}$ e fica assim:

$$P(Boeing|Delay) = \frac{P(Delay|Boeing) * P(Boeing)}{P(Delay)}$$

$$P(Boeing|Delay) = \frac{0.03 * 0.73}{0.0435} = 0.5034$$

Esse exemplo ilustrou o **Teorema de Bayes**, nos tornamos capaz de mudar o ponto de vista da probabilidade condicional.

Matematicamente podemos mostrar a fórmula dessa maneira:

$$P(A \cap B) = P(A|B) * P(B) = P(B|A) * P(A)$$

$$P(A|B) * P(B) = P(B|A) * P(A)$$

$$P(B|A) = \frac{P(A|B) * P(B)}{P(A)}$$

$$P(B|A) = \frac{P(A|B) * P(B)}{\sum_{i=1}^n P(B_i) * P(A|B_i)}$$

A fórmula genérica é um pouco diferente pois pode ser aplicada para casos com mais de 2 possibilidades, diferente do exemplo que usamos com 2 aviões.

Resumindo:

Probabilidade Condicional

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

A Lei da Probabilidade Total

$$P(B) = \sum_{i=1}^n P(A_i) * P(B|A_i)$$

Teorema de Bayes

$$P(A|B) = \frac{P(A) * P(B|A)}{\sum_{i=1}^n P(A_i) * P(B|A_i)}$$

Probabilidade Priori e Posteriori

Voltando ao Exemplo do Teste de HIV:

- A probabilidade de o resultado do teste ser **positivo** e a pessoa **não estar** infectada é de $P(T|D^C) = 0.0105$.
- A probabilidade de o resultado do teste ser **positivo** e a pessoa **estar** infectada é de $P(T|D) = 0.9978$.
- A probabilidade de a pessoa **estar** infectada é de $P(D) = 0.0014$ (a prevalência da HIV)
- A probabilidade de a pessoa **não estar** infectada é de $P(D^C) = 0.9986$

$P(T|D) = 0.9978$ significa que para pacientes infectados por HIV tem 99,78% de chance de o teste dar positivo, e $P(T|D^C) = 0.0105$ significa que para pacientes não infectados por HIV tem 1,05% de chance de o resultado dar positivo equivocadamente. O que demonstra que o teste é bem preciso.

Mas o paciente não sabe qual é sua condição, se ele está infectado D ou não D^C . Para ele o interessante é saber o ponto de vista contrário, quais as chance de ele realmente estar infectado dado que o Teste deu positivo $P(D|T)$. Com o Teorema de Bayes conseguimos calcular agora.

$$P(T) = P(D) * P(T|D) + P(D^C) * P(T|D^C)$$

$$P(T) = 0.0014 * 0.9978 + 0.9986 * 0.0105 = 0.0119$$

$$P(D|T) = \frac{0.0014 * 0.9978}{0.0119} = 0.1174$$

Veja que a probabilidade de o Teste ser positivo é baixa, mas essa probabilidade aumenta com a prevalência da doença. Esse parece ser apenas mais um conceito de probabilidade, mas na verdade é algo presente em nosso dia a dia.

Todos nós temos crenças que podem estar certas ou não. Podemos por exemplo achar que R não é uma habilidade útil de de aprender, mas ao ver muitas vagas de trabalho exigindo essa habilidade ter **evidências** que mudam essa crença e passamos a acreditar que é útil. E essa é a essência do Teorema de Bayes, todos nós temos crenças a **priori** (anterior a algo) e mudamos isso após evidências do contratio (**a posteriori**).

- Antes do Teste $P(D)$
- Depois do Teste $P(D|T)$

A probabilidade antes do teste é chamada de **Probabilidade a Priori** por acontecer antes, já após o teste chamamos de **Probabilidade a Posteriori**.