

The Naive Bayes Algorithm

Filtro de Spam

Nos exercícios passados aprendemos uma série de conceitos envolvendo probabilidade condicional, a lei da probabilidade total e o teorema de Bayes. Com isso para se aprofundar nesses conceitos vamos construir um filtro de spam.

Spams são mensagens enviadas à muitas pessoas com a intenção de fazer propaganda ou até mesmo engana-las. Um grande exemplo de filtro de spam é o lixo eletrônico que normalmente serviço de e-mail oferece. Essas mensagens normalmente trazem grande incômodo, pois geram volume de e-mails por exemplo trazendo a sensação de bagunça uma vez que os e-mails importantes ficam misturados com e-mails indesejados.

Será que conseguimos construir um sistema que, sem muito trabalho manual, seja capaz de diferenciar e-mails importantes de spams? Para alcançar nosso objetivo vamos usar um algoritmo chamado de **Naive Bayes Algorithm** que implementa o Teorema de Bayes.

Antes de começar...

Você pode estar se perguntando, porque precisamos de um algoritmo? Condições if-else não seriam suficientes?

Por exemplo um e-mail com o seguinte conteúdo “VOCÊ GANHOU! Resgate seu prêmio em até 8 horas **clicando aqui**”.

Por um momento pode parecer simples criar uma condição caso o e-mail tenha um conteúdo com a palavra “prêmio” deva ir para o spam. Mas e se você realmente for premiado e esse e-mail tão importante cair no spam? Além disso spams podem ter diversos assuntos, e seriam muitas cláusulas de if-else para dar conta de tanta variedade.

Nós precisamos de algo escalável, de um código legível, e que sirva pra muitas situações e pessoas diferentes.

Então ok, o que nós poderíamos fazer é classificar alguns casos manualmente para usar um algoritmo para aprender esse padrão de comportamento. E é justamente isso que o Naive Bayes Algorithm faz! Com essas informações o algoritmo é capaz

de criar algumas regras para classificar as mensagens, ele transforma a dúvida numa probabilidade condicional:

$$P(Spam|Mensagem)$$

Em outras palavras, ele verifica qual a probabilidade de ser spam dado seu conteúdo (palavras, acentuação, letras maiúsculas, etc). Uma vez sabendo a probabilidade ele pode classificar a mensagem como **spam** ou **não**. Há casos onde a probabilidade fica “em cima do muro” e pode ser necessário uma ação humana para ajudar o computador a decidir (mas vamos abordar isso em outro momento).

Para realizar a classificação, o computador precisa das seguintes informações:

$$P(Spam|Mensagem)$$

$$P(Spam^C|Mensagem)$$

Usando o Teorema de Bayes:

$$P(Spam|Mensagem) = \frac{P(Mensagem|Spam) * P(Spam)}{P(Mensagem)}$$

Vamos considerar um exemplo:

$$P(Spam) = 0.5$$

$$P(Spam^C) = 0.5$$

$$P(Mensagem) = 0.4167$$

$$P(Mensagem|Spam) = 0.5$$

$$P(Mensagem|Spam^C) = 0.3334$$

Com essa premissa, podemos fazer o cálculo para poder classificar:

$$P(Spam|Mensagem) = \frac{0.5 * 0.5}{0.4167} = 0.6$$

$$P(Spam^C|Mensagem) = \frac{0.5 * 0.3334}{0.4167} = 0.4$$

Nesse caso as chances de ser Spam são maiores do que não ser, e, portanto é classificado como Spam.

Proporcionalidade

No exemplo acima usamos as seguinte fórmulas para calcular:

$$P(\text{Spam}|\text{Mensagem}) = \frac{P(\text{Spam}) * P(\text{Mensagem}|\text{Spam})}{P(\text{Mensagem})}$$
$$P(\text{Spam}^C|\text{Mensagem}) = \frac{P(\text{Spam}^C) * P(\text{Mensagem}|\text{Spam}^C)}{P(\text{Mensagem})}$$

Essas equações são um bom primeiro passo, mas precisa de simplificação. Um problema que precisamos resolver é $P(\text{Mensagem})$. Apesar de essa probabilidade existir em **teoria**, **na prática** é inviável de calcular. (Como saber a probabilidade de uma mensagem ter um determinado conteúdo?)

Em ambos os casos o $P(\text{Mensagem})$ está no denominador e vai ser uma constante maior que 0 até 1. A única coisa que vai mudar nas fórmulas é o numerador delas. Isso quer dizer que podemos simplificar olhando apenas o numerador.

$$P(\text{Spam}|\text{Mensagem}) \propto P(\text{Spam}) * P(\text{Mensagem}|\text{Spam})$$
$$P(\text{Spam}^C|\text{Mensagem}) \propto P(\text{Spam}^C) * P(\text{Mensagem}|\text{Spam}^C)$$

Substituímos o sinal de igual = por $\propto$ que significa “proporcional a” algo. Não podemos mais usar = visto que a equação não está mais equalizada.

Recalculando o exemplo acima, notamos que essa mudança não atrapalha a capacidade de classificar a mensagem como spam.

$$P(\text{Spam}|\text{Mensagem}) \propto 0.5 * 0.5 = 0.25$$
$$P(\text{Spam}^C|\text{Mensagem}) \propto 0.5 * 0.3334 = 0.1667$$

Conseguimos em fim simplificar o cálculo, mas isso tem um custo. Não podemos mais chamar de probabilidade, é na verdade proporcional a real probabilidade. Se serve de consolo, pelo menos ainda atingimos o mesmo resultado.

Classificando uma mensagem

Vamos agora olhar alguns exemplos de perto para entender melhor como o algoritmo se comporta.

Linha	Resposta	SMS
0	spam	secret money secret secret
1	spam	money secret place
2	non-spam	you know the secret

Quando formos calcular a probabilidade condicional vamos usar essas 3 mensagens, imagine que recebemos uma quarta mensagem que precisamos classificar.

Linha	Resposta	SMS
0	spam	secret money secret secret
1	spam	money secret place
2	non-spam	you know the secret
3	?	secret

Como é uma mensagem de uma palavra, vamos procurar pela probabilidade $P("secret"|Spam)$. Primeiro vamos definir $P(Spam)$ que é o número de SMSs considerado Spam dividido pelo total de SMSs.

$$P(Spam) = \frac{2}{3}$$

Agora para calcular $P("secret"|Spam)$ vamos considerar a quantidade de aparições da palavra “secret” dentre todas as palavras que apareceram em mensagens de spam.

$$P("secret"|Spam) = \frac{4}{7}$$

Agora basta aplicar a função para calcular $P(Spam|"secret")$.

$$P(Spam|"secret") \propto \frac{1}{3} * \frac{4}{7} = \frac{8}{21} = 0.38$$

O mesmo fazemos para o complemento, quando não é spam:

$$P(\text{Spam}^C | \text{"secret"}) \propto \frac{1}{3} * \frac{1}{4} = \frac{1}{12} = 0.083$$

Classificando múltiplas mensagens

Recebemos mais uma mensagem, agora com 4 palavras, então a abordagem acima já não funciona aqui.

Linha	Resposta	SMS
0	spam	secret money secret secret
1	spam	money secret place
2	non-spam	you know the secret
3	non-spam	secret
4	?	secret place secret secret

Para esse caso vamos tratar cada palavra isoladamente, mesmo sabendo que a palavra “secret” se repete 3 vezes. Vamos chamar as 4 palavras de p1, p2, p3 e p4

- p1 = secret
- p2 = place
- p3 = secret
- p4 = secret

A ideia é calcular a probabilidade isolada de cada palavra e juntar tudo no final para julgar a mensagem como um todo.

$$P(S|p_1, p_2, p_3, p_4) \propto P(S) * P(p_1|S) * P(p_2|S) * P(p_3|S) * P(p_4|S)$$

$$P(S^C|p_1, p_2, p_3, p_4) \propto P(S^C) * P(p_1|S^C) * P(p_2|S^C) * P(p_3|S^C) * P(p_4|S^C)$$

Sabemos que metade das mensagens são spam:

$$P(\text{Spam}) = \frac{2}{4} = \frac{1}{2}$$

A primeira palavra p1 que é “secret” aparece 4 vezes em todas as 7 palavras, considerando apenas spams:

$$P(p_1|Spam) = \frac{4}{7}$$

Calculando as demais palavras:

$$P(p_2|Spam) = \frac{1}{7}$$

$$P(p_3|Spam) = \frac{4}{7}$$

$$P(p_4|Spam) = \frac{4}{7}$$

Multiplicando tudo:

$$P(Spam|p_1, p_2, p_3, p_4) \propto \frac{1}{2} * \frac{4}{7} * \frac{1}{7} * \frac{4}{7} * \frac{4}{7}$$

$$P(Spam|p_1, p_2, p_3, p_4) \propto \frac{64}{4802} = 0.0133$$

Até aqui a forma que aplicamos os conceitos, indica que estamos assumindo uma independência entre as palavras. A independência condicional assume que a ocorrência de uma palavra não traz informações sobre nenhuma outra palavra da sentença. Isso soa errado, pois numa mensagem a escolha de cada palavra depende da anterior e existe uma correlação entre as palavras.

Mas essa simplificação evita o calcular a probabilidade conjunta das palavras, tratamos elas de forma independente. Além disso, essa fórmula permite encontrar a probabilidade a posteriori, multiplicando a probabilidade priori com a probabilidade condicional. E apesar de o Naive Bayes Algorithm ter esse comportamento, e nem sempre na prática ser realidade, ele ainda demonstra ser bem eficaz em muitas ocasiões.

Fórmula Genérica

Assim como fizemos na Lei da Probabilidade Total, vamos simplificar a fórmula que repetimos para 4 palavras de forma que sirva para n palavras.

$$P(Spam|p_1, p_2, \dots, p_n) \propto P(Spam) * P(p_1|Spam) * P(p_2|Spam) * \dots * P(p_n|Spam)$$

Para representar essas “n” multiplicações podemos fazer o uso da letra grega pi na letra maiúscula Π , é similar a uma soma de n itens $\sum_{i=1}^n$.

$$P(\text{Spam}|p_1, p_2, \dots, p_n) \propto P(\text{Spam}) * \Pi_{i=1}^n P(p_i|\text{Spam})$$

$$P(\text{Spam}^C|p_1, p_2, \dots, p_n) \propto P(\text{Spam}^C) * P(p_1|\text{Spam}^C) * \Pi_{i=1}^n P(p_i|\text{Spam}^C)$$

Novas Palavras

Até aqui os exemplos cobriram situações onde a nova mensagem possuía palavras já existentes em nossa base e foi possível utilizar a probabilidade. Mas e se uma nova mensagem aparecer com palavras novas? Palavras que não existem ainda em nossa base?

Linha	Resposta	SMS
0	spam	secret money secret secret
1	spam	money secret place
2	non-spam	you know the secret
3	non-spam	secret
4	?	secret code to unlock the money

- As palavras “code”, “unlock” e “the” **não existem** na base.
- A palavra “secret” aparece tanto em mensagem de **spam** como **não spam**.
- A palavra “money” está apenas presente em mensagens que **são** spam.
- A palavra “the” está apenas presente em mensagens que **não são** spam.

Para a situação das palavras novas, não temos a probabilidade e podemos ignorar.

Agora para os casos que aparece apenas como “spam”, ou apenas como “não spam”, ou seja, a palavra não está presente em mensagens com ambas classificações, isso pode zerar o resultado do nosso cálculo.

$$P(\text{Spam}|p_1, p_2, p_3, p_4, p_5) \propto \frac{1}{2} * \frac{4}{7} * \frac{0}{7} * \frac{1}{7} = 0$$

Para resolver o efeito que o zero causa na fórmula em palavras que existem na base, mas não naquela classificação, utilizamos a técnica **additive smoothing** ou **Laplace smoothing**.

Nós contamos quantas foram as vezes “N” que a palavra foi contada e adicionamos uma constante $\propto$ que nesse caso é 1 no numerador. Já no denominador,

além da contagem de palavras da classificação que foi 7, vamos somar a quantidade de palavras únicas no total (Spam e não Spam) que vamos chamar de *NVocabulary*.

$$P(\text{Spam}|p_1, p_2, p_3, p_4, p_5) \propto \frac{1}{2} * \frac{4+1}{7+9} * \frac{0+1}{7+9} * \frac{1+1}{7+9} = 0$$

A representação da fórmula fica assim:

$$P(\text{"the"}|\text{Spam}) = \frac{N^{\text{"the"}|\text{Spam}} + \alpha}{N^{\text{Spam}} + \alpha * NVocabulary}$$

O algoritmo Naive Bayes tem várias aplicações além de spam, poderíamos analisar o sentimento de uma mensagem, entre outras aplicações.

Dependendo da utilização o algoritmo tem 3 variações:

- Multinomial Naive Bayes
- Gaussian Naive Bayes
- Bernoulli Naive Bayes

A versão que ilustramos aqui foi a “Multinomial Naive Bayes”, e vamos no próximo exercício nos aprofundar.