


Probability Distributions

Distribuição Uniforme

Nos exercícios até aqui, cobrimos vários tópicos relacionados à probabilidade, conceitos, fórmulas através de exemplos de cenários reais como jogar um dado, uma moeda, retirar uma carta. Em alguns casos a chance de um resultado é igual para todos elementos, ao jogar um dado as chances de sair 1 ou 6 são iguais.

```
dado_prob <- tibble(dados = seq(1,6),  
                    probs = 1/6)
```

```
dado_prob %>%  
  ggplot(aes(x=dados, y=probs)) +  
  geom_col()
```



Mas em geral isso não acontece, e veremos isso no decorrer dessa lição. Conhecer a distribuição de uma probabilidade nos ajuda a entender:

- Qual resultado tem mais chance de ocorrer?
- Qual seria a probabilidade de observar um intervalo de vários resultados ao invés de um?

Nesse caso do dado, a distribuição é *flat* pois todas as saídas tem as mesmas chances de ocorrer, o mesmo resultado aconteceria para jogar uma moeda. Normalmente é dado um nome para o formato da distribuição, nesse caso chamamos de distribuição **uniforme**.

Podemos inferir algumas informações ao se deparar com um gráfico como o mostrado acima, mesmo se o experimento fosse desconhecido.

- De olhar o eixo x sabemos que o espaço amostral é $\Omega = 1, 2, 3, 4, 5, 6$
- Sabemos que a probabilidade é algum valor entre 0 e 1, e que todas as saídas possíveis juntas somam 100%, ou seja se somarmos o resultado de todas as barras tem que somar 1.
- Sabemos que não existe probabilidade mais que 1 ou negativa

É importante destacar que todas as probabilidades tem essas características, a distribuição uniforme só nos ajuda mais intuitivamente a entender isso.

Função de Distribuição de Probabilidade

Não vamos ter o tempo todo um gráfico à nossa disposição para visualmente entender a distribuição de uma probabilidade. No entanto podemos escrever isso no formato de função. No caso de jogar um dado, reaproveitando novamente o exemplo do gráfico acima, poderíamos representa-lo assim:

$$P(X) = \frac{1}{6}, \text{ for } i \text{ in } [1, 2, \dots, 6]$$
$$P(X) = 0, \text{ elsewhere}$$

Aqui descrevemos primeiro quais as probabilidades dos resultados do espaço amostral, e em segundo informamos como lidar com os resultados que não fazem parte do espaço amostral, nesse caso a probabilidade é zero para todo resto que não seja de 1 a 6.

Sendo assim a probabilidade que vemos para o 1 também serve para o 6

$$P(X = 1) = P(X = 6) = \frac{1}{6}$$

Exemplo: Soma de 2 dados


Vamos imaginar um jogo onde é necessário somar o resultado de 2 dados jogados. Um jogador quer estudar a probabilidade das jogadas antes do grande jogo, para ter alguma vantagem.

```
dois_dados <-  
  matrix(c(2,3,4,5,6,7,  
           3,4,5,6,7,8,  
           4,5,6,7,8,9,  
           5,6,7,8,9,10,  
           6,7,8,9,10,11,  
           7,8,9,10,11,12),  
         nrow = 6,  
         ncol = 6,  
         dimnames=list(c("Jogada 1","Jogada 2","Jogada 3","Jogada 4","Jogada 5","Jogada 6"),  
                        c("Jogada 1","Jogada 2","Jogada 3","Jogada 4","Jogada 5","Jogada 6"))  
dois_dados
```

##	Jogada 1	Jogada 2	Jogada 3	Jogada 4	Jogada 5	Jogada 6
## Jogada 1	2	3	4	5	6	7
## Jogada 2	3	4	5	6	7	8
## Jogada 3	4	5	6	7	8	9
## Jogada 4	5	6	7	8	9	10
## Jogada 5	6	7	8	9	10	11
## Jogada 6	7	8	9	10	11	12

Colocando isso numa tabela fica claro que a soma dos dados resultando em 7 é o que mais ocorre. Se calcularmos a probabilidade dessas jogadas, temos um gráfico onde o pico está no 7 que se repete 6 vezes e faz uma curva simétrica para os dois lados até atingir os extremos 2 e 12 que apenas acontecem uma vez.

```
probabilidade <-  
  dois_dados %>%  
  as.data.frame() %>%  
  pivot_longer(cols = everything(), names_to = "jogadas", values_to = "resultado") %>%  
  group_by(resultado) %>%  
  summarise(contagem = n()) %>%  
  mutate(probabilidade = contagem/sum(contagem))  
  
probabilidade %>%  
  ggplot(aes(x=resultado, y=probabilidade)) +  
  geom_col()
```



Ou seja para o jogo, as chances de conseguir um 7 são maiores e se o jogo depender disso terá mais chances de ganhar.

Probabilidade Cumulativa

Continuando o último exemplo da soma dos 2 dados, vimos que tanto no gráfico quanto pela função que podemos encontrar facilmente a probabilidade de um resultado. Mas e se nosso interesse está em mais de um resultado?

Digamos que queremos saber a probabilidade de a soma ser menor igual a 3? Nesse caso estamos falando de 2 resultados, 2 e 3, sendo que o 2 tem apenas 1 chance de acontecer, e 3 tem 2 chances de acontecer.

$$P(X \leq 3) = P(X = 2) + P(X = 3) = \frac{1}{36} + \frac{2}{36}$$

Quando apresentamos uma condição que abrange vários resultados, nós estamos falando de **Probabilidade Cumulativa**. É esperado, quando se fala em probabilidade cumulativa, de ir juntando as probabilidades de resultados até certo ponto, normalmente usando menor, menor igual, maior igual, etc.

Se já conseguimos descobrir a probabilidade da condição **menor igual a 3** podemos descobrir a probabilidade de **maior que 3** que abrange todos resultados que não entraram na primeira condição, são o complemento.

$$P(X > 3) = 1 - \frac{3}{36} = \frac{33}{36}$$

Dessa forma podemos generalizar a fórmula dessa forma:

$$P(X > n) = 1 - P(x \leq n)$$

De experimentos aleatórios para experimentos reais

Usar exemplos de dados nos ajudam a entender sobre como a distribuição de probabilidade funciona. E isso vai ser importante visto que no Teste de Hipóteses precisamos entender como os dados estão distribuídos.

Nós podemos entender o processo de coleta de dados como um experimento por si só, pense num escritório onde se está coletando o peso das pessoas. É um dado contínuo e se escolhermos alguém aleatoriamente não temos como afirmar com certeza qual será seu peso.

Então conforme coletamos dados, estamos essencialmente executando um experimento aleatório, e ao gerar uma visualização dos dados, estaremos vendo uma distribuição dos dados empírica. São dados observados, evidências, de algo que realmente aconteceu.

E você pode se perguntar: tá e qual a diferença entre a distribuição de probabilidade e distribuição empírica? Para calcular a exata probabilidade de cada resultado e plotar gráficos da distribuição de probabilidade precisamos saber o espaço amostral completo. Na vida real dificilmente vamos ter todos esses dados, então nos baseamos nas observações.

Se coletarmos dados do peso de 50 pessoas, os dados vão representar bem aquelas 50 pessoas, mas não as pessoas no geral. Mas conforme nós coletamos mais e mais dados, eles passam a cada vez se aproximar mais da distribuição de probabilidade teórica.

A Distribuição Normal

Sem dúvidas, a distribuição mais famosa é a **distribuição normal**. Às vezes chamada de curva do sino pelo formato característico, muitos fenômenos da vida podem ser visualizados nesse formato, um exemplo é a distribuição de QI.

Imaginando que temos uma distribuição empírica que tem o formato da distribuição normal, apesar de não ser 100% exato é uma boa aproximação e portanto podemos usufruir de funções no R que são dedicadas a esse formato.

Todas as características que aprendemos ao longo do curso se aplicam à distribuição normal, mas temos que nos atentar de algumas diferenças. Nos exemplos que trouxemos (exceto o peso) foram todos distribuições discretas, o que é diferente de dados contínuos. Por exemplo a jogada de 2 dados somados tem valores de 2 a 12, porém sem decimais como 4.5.

A distribuição normal é contínua, significa que pode assumir qualquer valor dado um intervalo.

Outra característica dessa distribuição é que basicamente 2 valores a definem: **a média e a variância**. Tendo esses valores já é possível plotar no gráfico a posição da curva e sua abertura, se tem um pico maior ou é mais achatada.

Função de Densidade de Probabilidade

Em caso de curiosidade, essa é a fórmula que produz uma distribuição normal:

$$P(X = x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x - \mu)^2}$$

A média é representada pela letra μ e a variância por σ^2 . Um resultado específico é representado por x , enquanto que o experimento em si é X . Podemos ler $P(X = x)$ como “a densidade de probabilidade que o experimento assume com o valor x ”. Chamamos de densidade visto que aquele valor específico não é uma probabilidade, é só uma forma de ilustrar o quanto um elemento está próximo do outro. Se 0 tem maior densidade que 1, significa que 0 tem mais chances de acontecer.

Na prática não vamos utilizar essa fórmula quando trabalhamos com a linguagem R, visto que temos muitas funções que podem nos apoiar nos cálculos. Uma função famosa é a `dnorm()`, onde o “d” é de densidade e “norm” faz referência a distribuição normal. Ela precisa de um argumento por padrão, e tem 2 opcionais.

O primeiro argumento é o x que é o valor para o qual queremos ver a densidade $P(X = x)$. O 1º argumento opcional é “mean”, a média da distribuição. O 2º

argumento “sd” é o desvio padrão, se você está trabalhando com a variância que é σ^2 é preciso calcular a raiz quadrada da variância para obter o desvio padrão. Caso você não informe os argumentos opcionais, a função vai assumir mean = 0 e sd = 1 por padrão.

Vamos imaginar que queremos ver a densidade de um exemplo hipotético onde uma pessoa leva 90 segundos estudando um tópico com uma variância de 15. O resultado da densidade de probabilidade é de 0.10.

```
dnorm(90, mean = 90, sd = sqrt(15))
```

```
## [1] 0.1030065
```

Probabilidade Cumulativa

E como calculamos a probabilidade cumulativa numa curva normal? Isso requer um pouco de conhecimento em cálculo, mas felizmente temos a função pronta `pnorm()` para nos ajudar, é bastante similar a função que vimos logo acima. A diferença é que o argumento obrigatório não vai olhar apenas aquele valor isoladamente, ele vai calcular até aquele valor $P(X \leq x)$.

Vamos pegar um exemplo simples, uma curva normal de média 0 e desvio padrão 1, onde queremos calcular a probabilidade cumulativa de 1.


```
pnorm(1)
```

```
## [1] 0.8413447
```

Ou seja isso vai abranger desde o valor mais negativo da ponta esquerda do gráfico, passar pela média até o primeiro desvio padrão. Isso representa mais de 84% de probabilidade.

```
pnormGC(1, mean=0, sd=1, graph=TRUE)
```

Normal Curve, mean = 0 , SD = 1
Shaded Area = 0.8413



```
## [1] 0.8413447
```


Agora se quisermos um intervalo da curva, que não considere o começo da curva, por exemplo, podemos calcular assim:

```
pnorm(1) - pnorm(-1)
```

```
## [1] 0.6826895
```

```
pnormGC(c(-1,1), region = "between", mean=0, sd=1, graph=TRUE)
```

Normal Curve, mean = 0 , SD = 1
Shaded Area = 0.6827



```
## [1] 0.6826895
```